


# Introducción al Machine Learning

El Machine Learning (ML) está transformando industrias. Permite a las máquinas aprender de datos. Los modelos hacen predicciones y decisiones. Es diferente de la IA tradicional. También es diferente de Data Science. ML es relevante en salud, finanzas y marketing.



# ¿Qué es Machine Learning?

## Machine Learning (ML)

Entrena modelos con datos. Luego los usa para predecir.

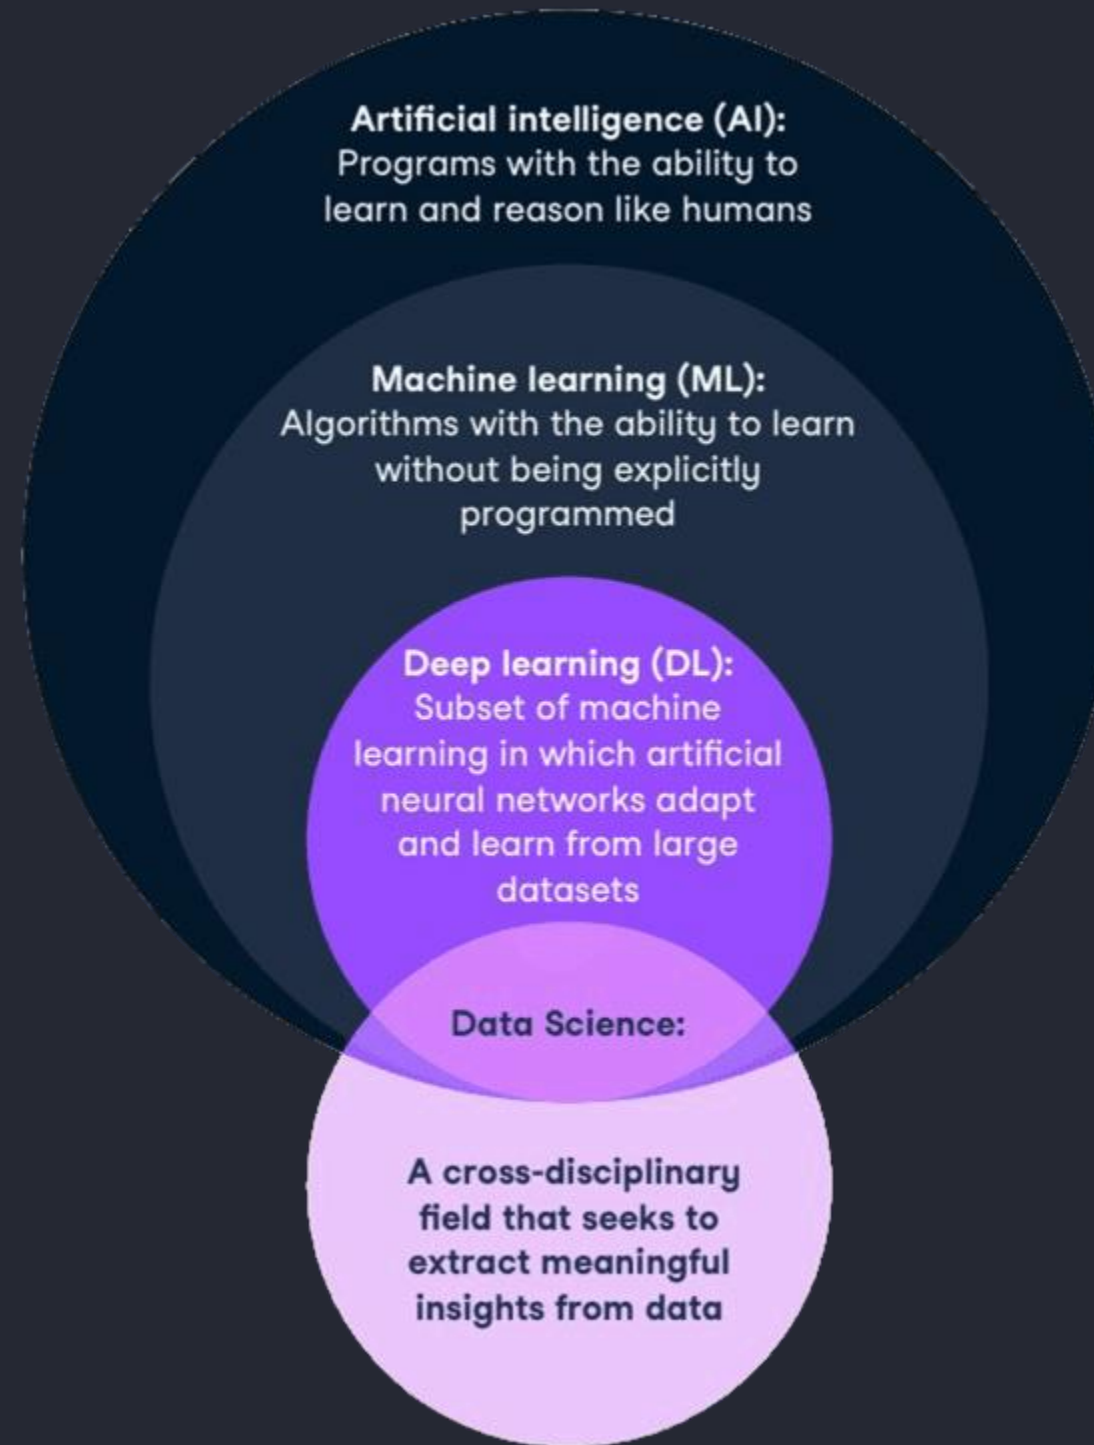
## Inteligencia Artificial (IA)

Crea sistemas inteligentes. Simulan la inteligencia humana.

## Data Science

Extrae conocimiento de los datos. Usa estadística y ML.

# Diferencia entre IA, ML, DL y DS



# Ejemplos Cotidianos de ML



## Netflix

Recomienda películas y series. Se basa en tus gustos previos.



## Detección de Spam

Filtra correos no deseados. Aprende de los patrones de spam.



## Autos Autónomos

Navegan sin conductor. Procesan datos de sensores.



# Aprendizaje Supervisado

1

## Clasificación

Identifica categorías. Por ejemplo, spam o no spam.

2


## Regresión

Predice valores continuos. Por ejemplo, precios de casas.

3

## Datos Etiquetados

**Features** (características) vs. **Labels** (etiquetas).





# Aprendizaje No Supervisado

## Clustering

Agrupar datos similares.  
Identificar patrones ocultos.

## Datos Sin Etiquetas

Encuentra estructura en los  
datos. No requiere supervisión.

## Ejemplo

Segmenta clientes por comportamiento. Mejora el marketing.



# Aprendizaje por Refuerzo

1

Agente

Toma decisiones en un entorno.

2

Recompensa

Recibe retroalimentación positiva.

3

Penalización

Recibe retroalimentación negativa.



# Términos Fundamentales

## Dataset

Conjunto de datos utilizados. Para entrenar el modelo.

## Modelo vs. Algoritmo

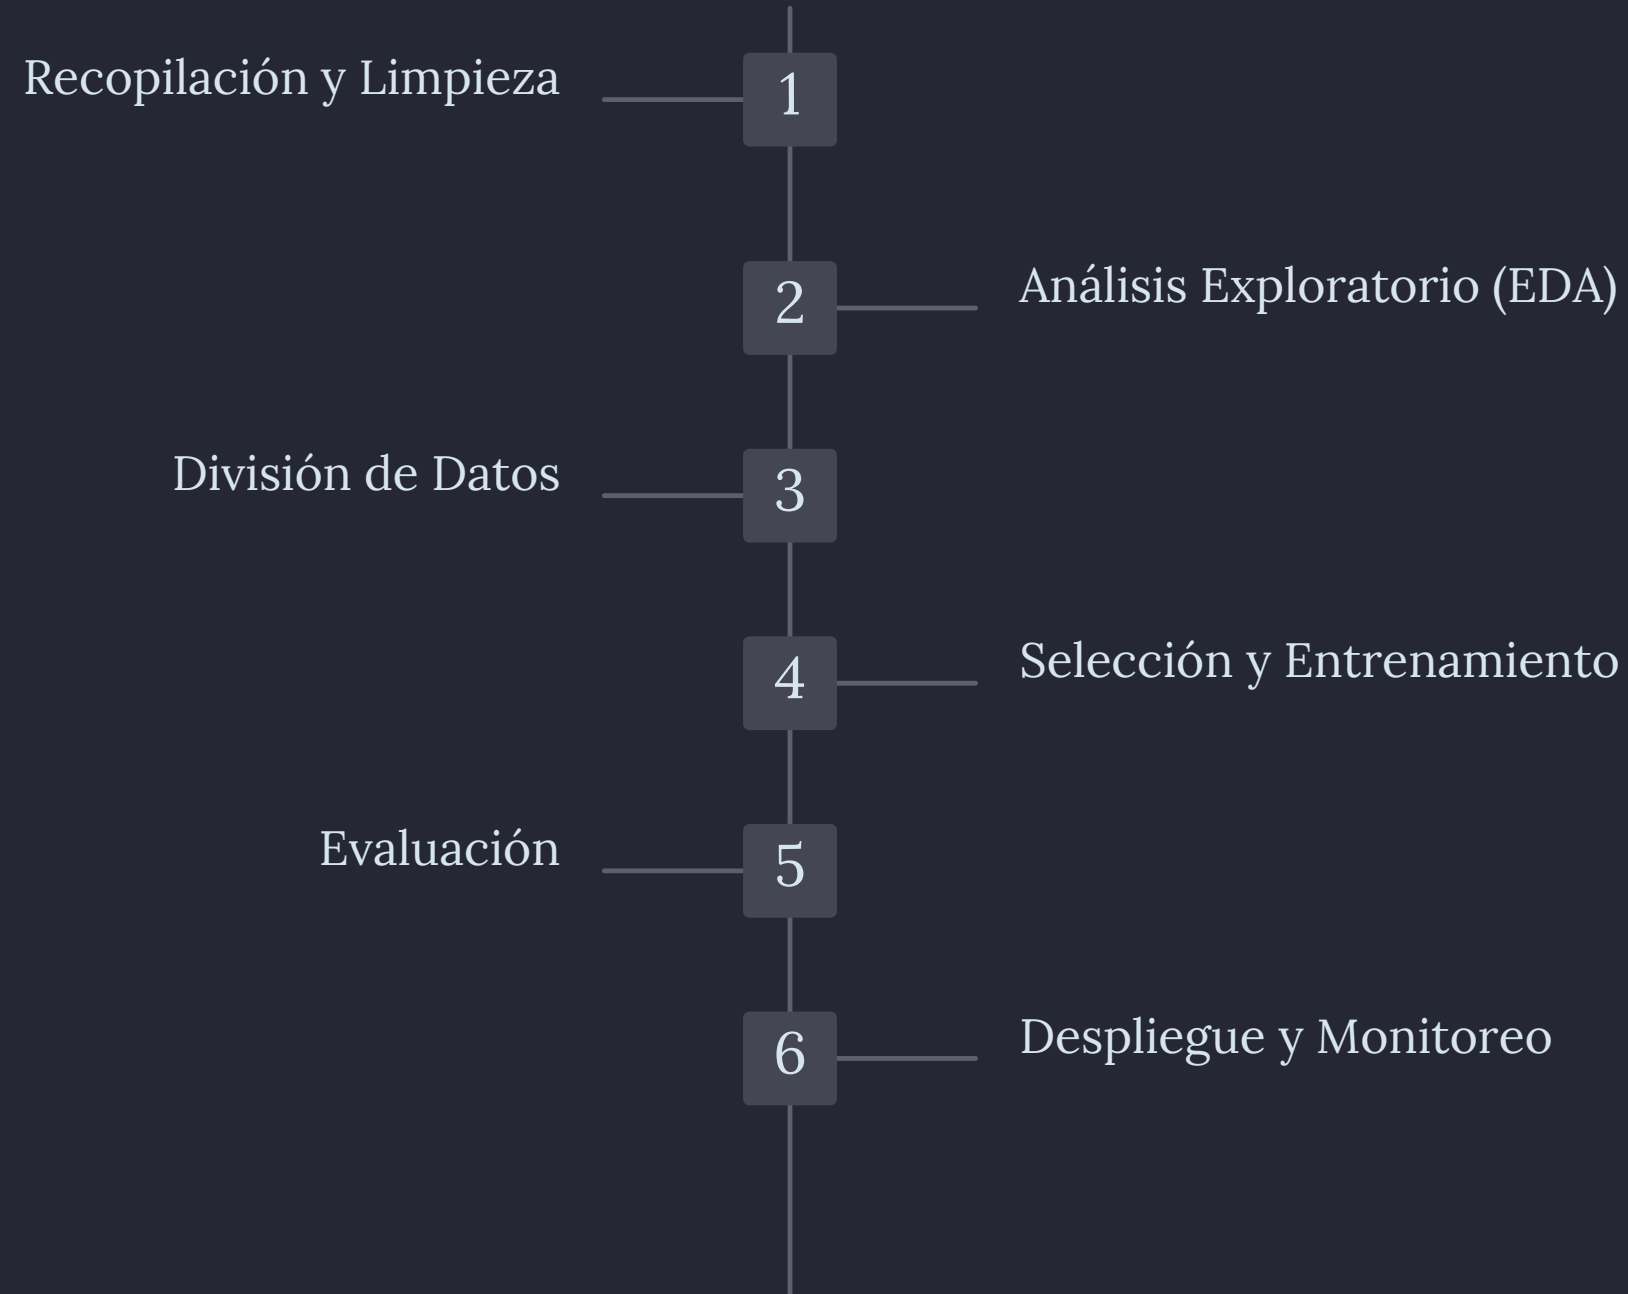
Regresión lineal vs. K-medias. Uno es la instancia del otro.

## Entrenamiento y Validación

Evita el overfitting. Ajusta los hiperparámetros.



# Flujo de Trabajo en ML



# Retos Comunes en ML

Calidad de Datos  
Valores faltantes, ruido.



Sesgo y Varianza  
Bias-variance tradeoff.


Ética en ML  
Sesgos, privacidad.

# Explorando el Machine Learning: Desde los Clásicos hasta el Deep Learning

Esta presentación ofrece una visión general del Machine Learning, desde los modelos clásicos hasta las redes neuronales. Exploraremos conceptos clave y la importancia del preprocesamiento de datos.

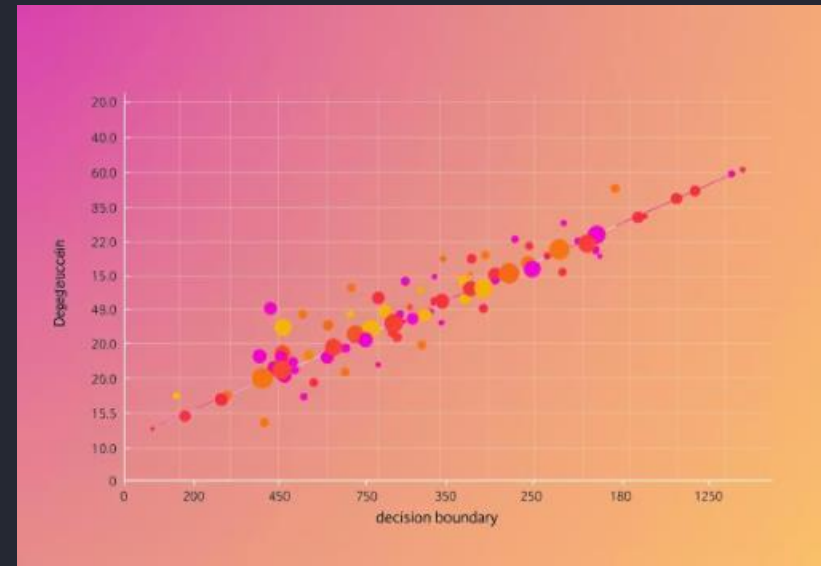


# Modelos de Clasificación Clásicos



# Árboles de Decisión

Simple y fáciles de interpretar. Dividen los datos en función de decisiones secuenciales.



# Regresión Logística

Utilizada para predecir la probabilidad de pertenencia a una clase.



## K-Vecinos Cercanos (KNN)

Clasifica basándose en la mayoría de las clases de sus vecinos más cercanos.

Estos modelos son fundamentales para entender los algoritmos de clasificación.



# Modelos de Regresión Clásicos

1

## Regresión Lineal

Modela la relación entre variables mediante una línea recta.


2

## Regresión Polinómica

Extiende la regresión lineal utilizando funciones polinómicas.

La regresión se usa para predecir valores continuos, como precios o temperaturas.





# Clustering con K-Means

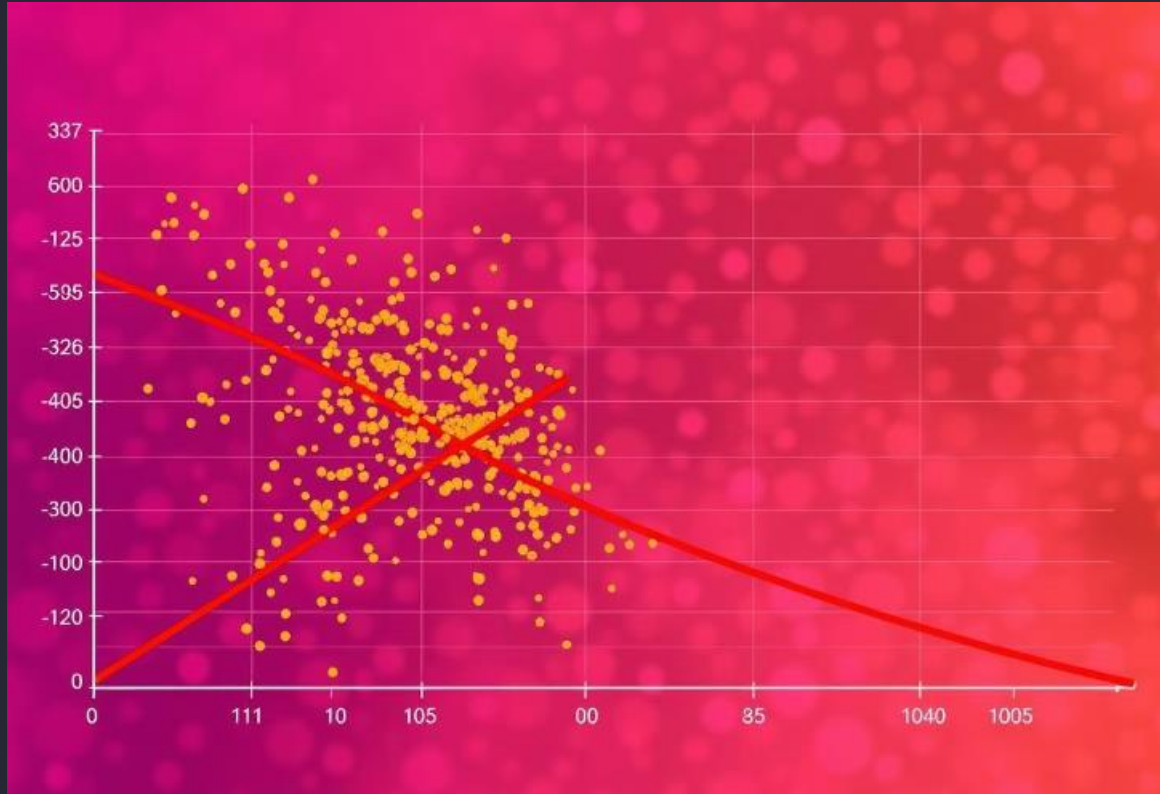


## Agrupamiento

K-Means agrupa datos en  $k$  grupos. Minimiza la distancia dentro de cada grupo.

Esencial para la segmentación y el descubrimiento de patrones en datos no etiquetados.

# Overfitting vs. Underfitting



## Overfitting

El modelo se ajusta demasiado a los datos de entrenamiento. Generaliza mal a nuevos datos.


El equilibrio es crucial para un buen rendimiento del modelo.



## Underfitting

El modelo es demasiado simple. No captura la complejidad de los datos.

# Bias-Variance Tradeoff



Alto Bias  
Suposiciones fuertes  
sobre los datos.

Alta Varianza

Sensible a pequeñas fluctuaciones  
en los datos de entrenamiento.




Equilibrio

Encontrar el equilibrio es clave.

Minimizar ambos es el objetivo principal.

# Bias-Variance Tradeoff



# Normalización y Escalado de Datos

## 1 Importancia

Asegura que todas las variables tengan un rango similar. Mejora el rendimiento del modelo.


## 2 Técnicas

Min-Max scaling, estandarización (Z-score). Ayudan a prevenir el dominio de una variable sobre otra.

Estos procesos son esenciales para muchos algoritmos de ML.



Conlusion Matrix



# Métricas de Evaluación

## Accuracy

Mide la proporción de predicciones correctas.

## Precisión

Proporción de verdaderos positivos entre los predichos como positivos.

## Recall

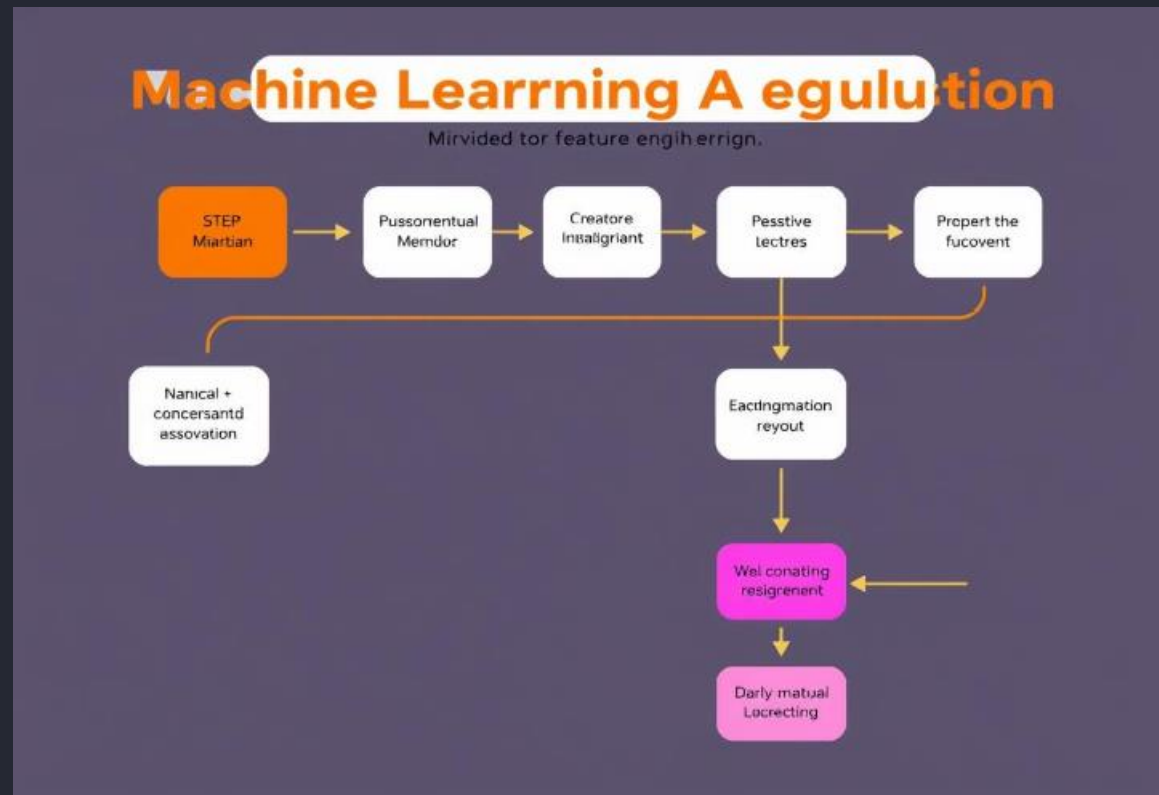
Proporción de verdaderos positivos entre los que realmente son positivos.

## F1-score

Media armónica de precisión y exhaustividad.

Seleccionar la métrica adecuada depende del problema.

# ML Clásico vs. Deep Learning



## Machine Learning Clásico

Requiere ingeniería de características manual. Modelos más simples.

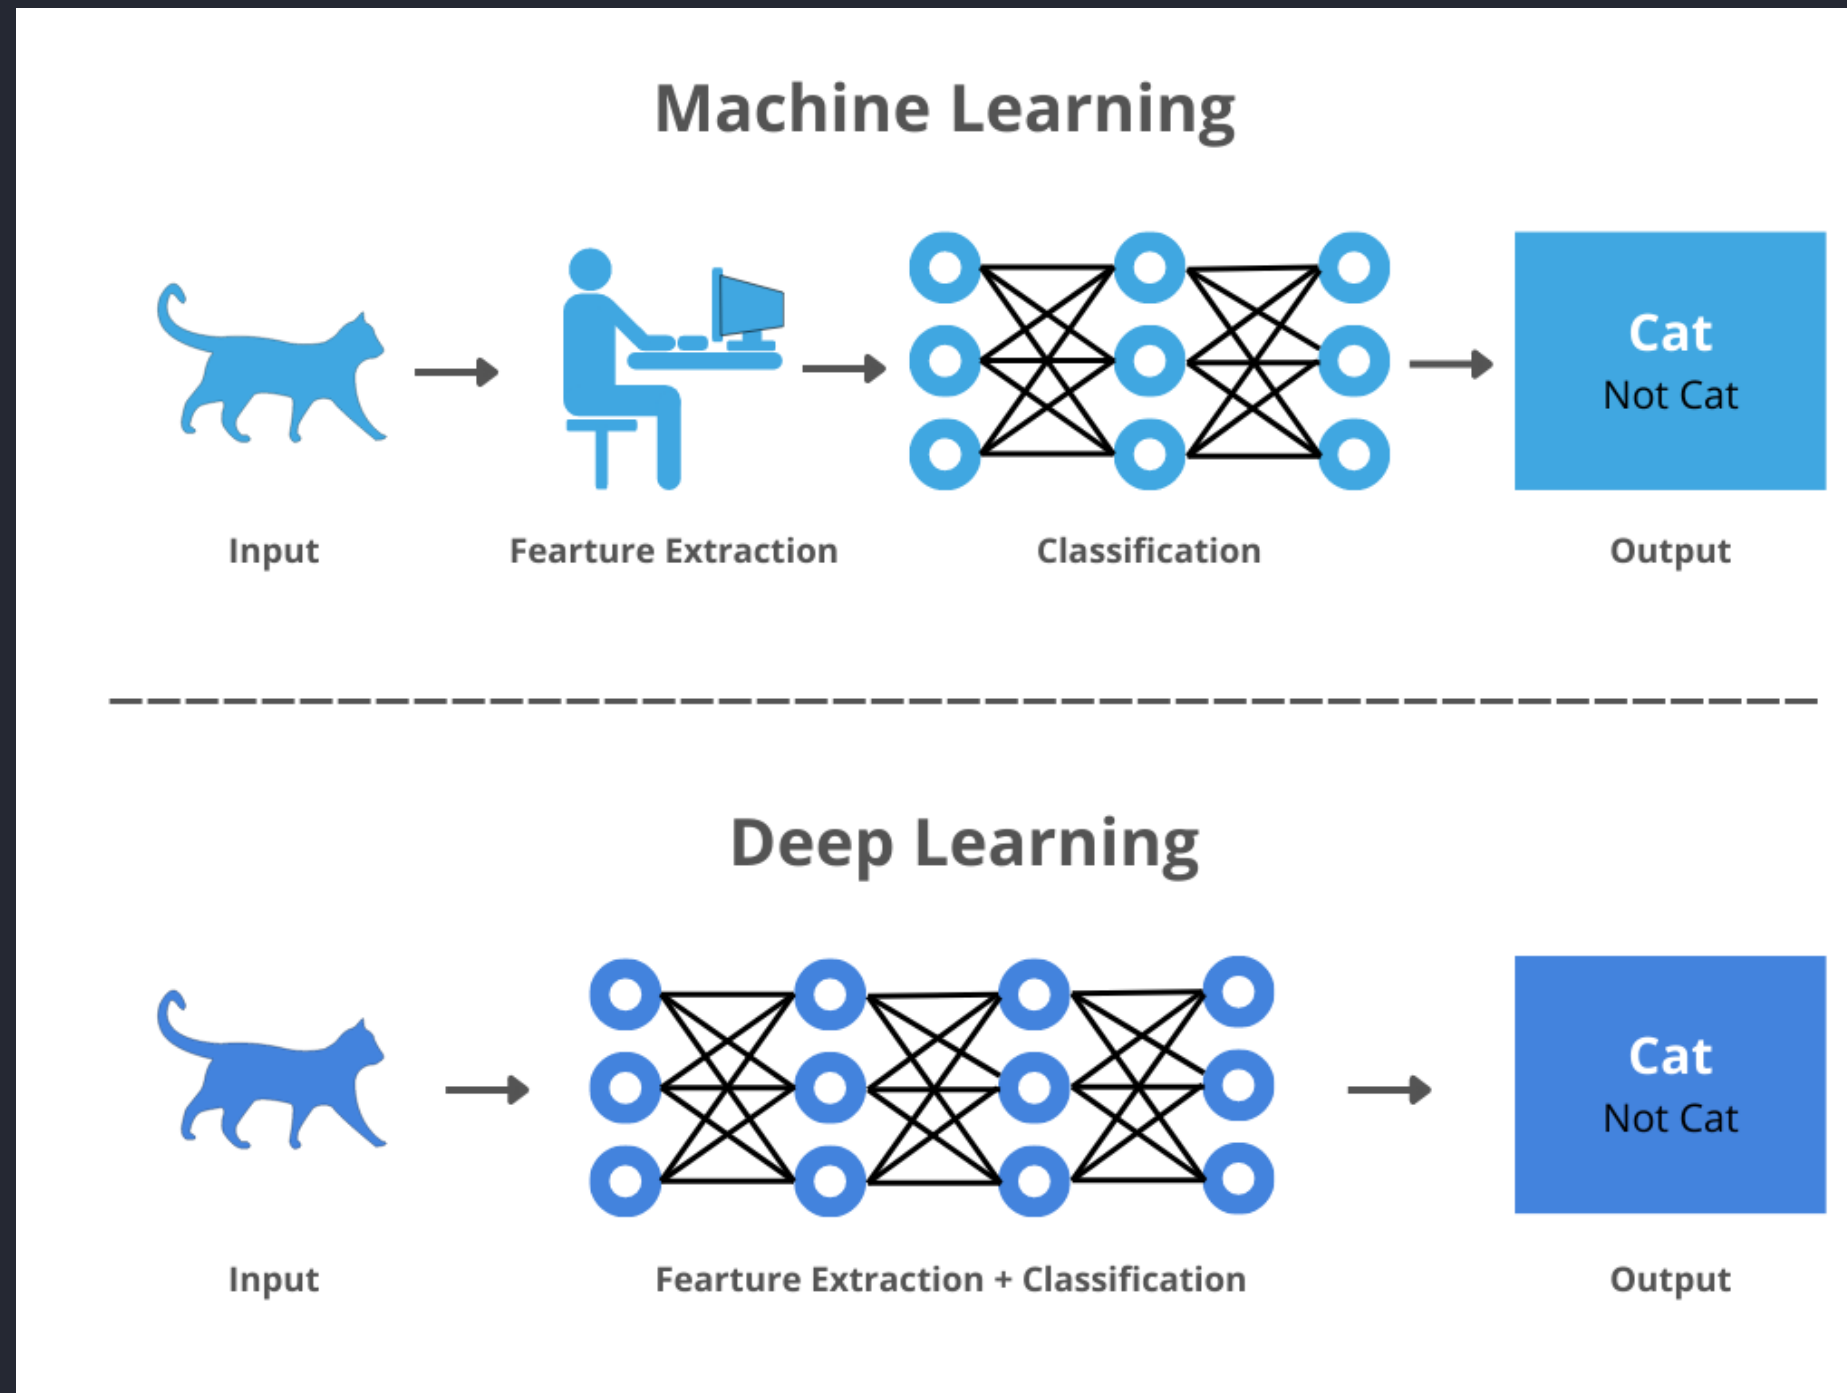
Deep Learning destaca en tareas complejas como visión artificial y procesamiento del lenguaje natural.



## Deep Learning

Aprende características automáticamente. Requiere grandes cantidades de datos y poder computacional.

# ML Clásico vs. Deep Learning



# Conclusiones y Próximos Pasos

1

## Repaso

Hemos cubierto modelos clásicos, conceptos clave.

2

## Práctica

Se experimentara con diferentes modelos y conjuntos de datos.

3

## Exploración

Profundiza en áreas específicas que te interesen.

El Machine Learning es un campo en constante evolución. ¡Sigue aprendiendo y explorando!







# Conclusiones Clave

Machine Learning es una herramienta poderosa. Permite predecir y tomar decisiones. Hay diferentes tipos de ML. Cada uno con sus propias aplicaciones.

El proceso de ML tiene varios pasos. Es importante abordar los retos comunes. La ética es fundamental.