

Redes Neuronales

Este capítulo explora las redes neuronales con conexiones hacia adelante, incluyendo el Perceptrón, ADALINE, MADALINE y la red Back-Propagation. Aprenderemos sobre su arquitectura, funcionamiento y reglas de aprendizaje.



Introducción a las Redes Neuronales con Conexiones Hacia Adelante

Perceptrón

El primer modelo de red neuronal artificial, desarrollado por Frank Rosenblatt en 1958. Capaz de aprender a reconocer patrones sencillos.

Redes ADALINE

Una mejora del Perceptrón, capaz de resolver problemas de regresión lineal. Utiliza un algoritmo de aprendizaje adaptativo.

Redes MADALINE

Una red de múltiples ADALINE, capaz de resolver problemas más complejos. Se utiliza para la clasificación y la predicción.

Red Back-Propagation

Un algoritmo de aprendizaje que se utiliza para entrenar redes neuronales multicapa. Permite la adaptación de los pesos en todas las capas.




El Perceptrón: Un Clasificador Lineal

El Perceptrón es un clasificador binario lineal que mapea una o más entradas en una salida deseada. Su algoritmo de aprendizaje es supervisado, donde los pesos se ajustan para minimizar el error entre la salida predicha y la salida deseada.


El Perceptrón sigue siendo una red rápida y confiable para problemas que puede resolver, y su comprensión es fundamental para comprender redes más complejas.

Arquitectura del Perceptrón





La red del Perceptrón se compone de neuronas interconectadas, cada una con un conjunto de pesos que determinan su influencia en la salida. La salida de la red es una función de activación aplicada a la suma ponderada de las entradas.

La matriz de pesos W representa las conexiones entre las entradas y las neuronas, mientras que el vector de sesgo b desplaza el límite de decisión.



Arquitectura del Perceptrón



$$\sum_{i=1}^R x_i w_i + b$$

$$\hat{y}_i = f \left(\sum_{i=1}^R x_i w_i + b \right)$$

La estructura básica de un Perceptrón consiste en:

Entradas (x_1, x_2, \dots, x_R): Son los valores de entrada que recibe la red.

Pesos (w): Son valores que multiplican a cada entrada y determinan la importancia de cada una.

Bias (b): Es un término adicional que permite ajustar la salida.


Función de activación $H(n)$: Generalmente es una función escalón, que produce una salida discreta (0 o 1).

Cada neurona divide el espacio de entrada en dos regiones separadas por una línea de decisión.


Límite de Decisión del Perceptrón

El límite de decisión del Perceptrón es una línea o hiperplano que separa el espacio de entrada en dos regiones, donde cada región corresponde a una clase de salida. La ecuación del límite de decisión se determina por los pesos y el sesgo.

El límite de decisión es ortogonal al vector de pesos, lo que significa que la dirección del vector de pesos determina la orientación del límite de decisión.



Límite de Decisión del Perceptrón



$$w_{1,1} = 1, w_{1,2} = 1, b = -1$$

El límite de decisión es entonces:


$$n = {}_1w^T p + b = w_{1,1}p_1 + w_{1,2}p_2 + b \\ \equiv p_1 + p_2 - 1 \equiv 0$$

La salida de esta red esta determinado por:

$$a = H(w_{1,1}p_1 + w_{1,2}p_2 + b)$$

Entonces el límite de decisión es:

$$n = {}_iw^Tp + b = w_{1,1}p_1 + w_{1,2}p_2 + b = 0$$



Límite de Decisión del Perceptrón

El límite de decisión es entonces:



$$n = {}_1 w^T p + b = w_{1,1} p_1 + w_{1,2} p_2 + b = p_1 + p_2 - 1 = 0$$

Esto define una línea en el espacio de entradas, en un lado de la línea la salida de la red será 0 y en el otro lado la salida será 1. Para dibujar la línea, se puede encontrar los puntos donde se cruza con los ejes p_1 y p_2 .

Para encontrar la intercepción p_2 , se considera $p_1 = 0$.

$$p_2 = -\frac{b}{w_{1,2}} = -\frac{-1}{1} = 1$$

$$p_1 = -\frac{b}{w_{1,1}} = -\frac{-1}{1} = 1$$



Regla de Aprendizaje del Perceptrón

La regla de aprendizaje del Perceptrón ajusta los pesos de las conexiones para minimizar el error entre la salida predicha y la salida deseada. La regla de aprendizaje se basa en la diferencia entre la salida deseada y la salida actual, y se aplica a cada peso de la red.

La taza de aprendizaje α controla la velocidad de aprendizaje, determinando cuánto se ajustan los pesos en cada paso de aprendizaje.

Regla de Aprendizaje del Perceptrón

La regla de aprendizaje del perceptrón se define como:


$$_1w(k+1) = _1w(k) + \alpha e p = _1w(k) + \alpha(t - a)p$$

$$b(k+1) = b(k) + \alpha e = b(k) + \alpha(t - a)$$

donde:

- α es la tasa de aprendizaje ($0 < \alpha \leq 1$).
- t es la salida deseada.
- a es la salida actual.

Perectrón Learning



Algoritmo de Aprendizaje del Perceptrón

1 Inicialización

Se asignan valores aleatorios a los pesos y al umbral.
pesos (w_i)
umbral (θ_i)

2

Presentación de un Patrón

Se presenta un nuevo patrón de entrada y la salida esperada.

$$X_p = (x_1, x_2, \dots, x_N)$$
$$d(t)$$

3

Cálculo de la Salida
Se calcula la salida actual utilizando la función de activación.

$$y(t) = f[\sum_i w_i(t)x_i(t) + \theta]$$

4

Adaptación de los Pesos

Se ajustan los pesos utilizando la regla de aprendizaje del Perceptrón.

$$w_i(t+1) = w_i(t) + \alpha[d(t) - y(t)]x_i(t)$$

Ejemplo de Aprendizaje del Perceptrón


Inputs	Weights	Outputs	Weight	Outpnurs
Frat:	380.40	16.3	219	1.0
	20y, 3tx:::	17.9	160	
	20y.16	16.0	220	4.0
Errors	190.10	37.4	179	3.0
	25y, 1et:::	17.3	129	2.0
	10y.19	11.5	250	1.0
Errors:	596.10	20.9	270	1.0
Frat:	30y.10	17.5	155	1.0
	28y, 2tx:::	51.9		
	20y.19	57.9	226	1.0
Erat:	30y.10	32.5	129	1.3
	30y.10	16.9	220	

Este ejemplo ilustra el proceso de aprendizaje del Perceptrón para la función OR. Se muestra como se ajustan los pesos en cada paso para minimizar el error y lograr la clasificación correcta.

El algoritmo se repite hasta que el error es cero o menor que un valor preestablecido, lo que indica que la red ha aprendido la función OR.

Ejemplo. Se tiene una neurona con dos entradas, umbral y una salida, la cual debe realizar la función OR. Donde, sean inicialmente los valores elegidos aleatoriamente: $w_1 = 0.5$, $w_2 = 1.5$, $b = 1.5$ y $\alpha = 1$.

Ejemplo de Aprendizaje de temperatura



$$^{\circ}\text{F} = (^{\circ}\text{C} \times 1.8) + 32$$